

# 汤林夕

☎ 19922109544 ✉ 1803554228@qq.com

📅 24 岁 🧑 男 🎓 应届生 🎯 AI Agent开发工程师 📺 抖音博主：欧皓辰我选你。分享Agent技术



## 教育背景

西南科技大学

计算机科学与技术 (硕士)

2024.09 - 2027.07

• GPA 3.4/4.0 专业排名前30%，主修软件工程，**研究方向**：图像分割模型蒸馏，**项目方向**：智能体+后端开发

## 实习与项目经历

小红书-DearAua (AI陪伴)

AI NATIVE 用户记忆与全栈业务开发

2026.09 - 至今

**技术栈**：Go、Thrift RPC、GORM、MySQL、Redis、Edith API 网关、Swift、SwiftUI、MVVM

**APP 上线情况**：已上线 iOS 与 Android 双端，覆盖 App Store、华为及荣耀等应用市场

**项目简介**：Aura 是一款融合 AI 与命理文化的个性化生活陪伴 iOS 应用，围绕“了解自己、获得日常启发、记录愿望与持续交流”构建产品体验。**核心功能**包括 AI 对话、好运日报、答案之书、心愿日记及个人画像与时间轴；结合用户基础资料、八字星盘、环境信息与历史互动，提供个性化日报、生活建议和互动问答，并通过日记与时间轴沉淀用户的表达和生活记录。

项目采用 **SwiftUI** 构建原生客户端，服务端基于 **Go** 与 **Thrift RPC** 提供用户管理、内容生成、会话交互及数据服务，通过 **公司 Edith API 网关** 统一接入客户端 HTTP 请求。**底层使用 MySQL 持久化用户与业务数据**，**Redis 管理缓存及会话状态**，并结合大模型、用户画像与记忆机制组织个性化上下文，支撑日报生成、连续对话和日记互动等核心场景

**个人职责**：

- **结构化用户记忆**：参与用户长期记忆模块开发，基于 MySQL 管理用户偏好、个人资料、习惯与目标等结构化事实；支持记忆更新、撤回及分类禁记策略，在对话前加载有效记忆，为个性化回复提供依据。
- **会话上下文管理**：参与会话记忆与上下文组装开发，结合 Redis 会话快照管理近期原文、分段摘要及当前交互状态；按 Token 预算组织历史上下文，通过 Episode 分段摘要与 Rollup 汇总保留旧对话中的关键事项、用户边界和未完成承诺。
- **iOS 原生交互**：基于 SwiftUI 与 MVVM 实现反馈信箱交互原型，覆盖信封列表、拆信阅读、反馈编辑与本地图片预览；通过独立 ViewModel 管理页面状态、草稿和异步图片任务，实现缩略图降采样及任务取消处理。
- **反馈业务后端**：基于 Go、GORM 设计会话、消息、附件三类数据模型，实现反馈创建、消息追加、历史查询与官方回复等能力；接入公司媒体服务保存图片，数据库维护文件标识及附件元数据。
- **接口与工程交付**：编写 Thrift 接口契约及 RPC 实现，完成 Go SDK 更新、测试泳道部署与创建反馈接口的网关配置发布；补充请求重放、权限隔离、分页及字段映射等自动化测试。

**技术亮点**：

- **记忆提取与按需注入**：在会话回复后异步调用 LLM 提取稳定、用户明确表达的事实，结合置信度与禁记策略过滤候选；采用“记忆目录 → 相关引用选择 → 完整事实加载”的方式组织长期记忆，控制无关内容进入模型上下文。
- **分层压缩与一致性**：区分会话级短期上下文和跨会话长期事实，保留近期原文并分层压缩旧对话；通过软阈值触发后台压缩、硬阈值触发请求前压缩，使用 Redis 单键快照与 CAS 版本校验协调消息追加和摘要更新。
- **反馈写入一致性与幂等**：使用事务保证会话、首条消息及附件原子写入，结合复合唯一键与请求指纹识别重复提交及内容冲突；追加消息时通过会话行锁分配递增序号。
- **轻量拆信红点**：基于最新官方回复序号与用户拆信位置判断红点状态，满足异步反馈场景，避免维护逐消息已读状态。

中文在线——AI 短剧智能体生产平台

Agent 工具与素材检索入库

2026.05 - 2026.09

**技术栈**：TypeScript、Python、React、Fastify、PostgreSQL / RDS、Milvus、TOS、Pi Agent、LangChain、Kubernetes、Docker

**Github**：K80Tom/zhongwen-shortdrama-main

**URL (测试环境)**：<http://shortdrama-main-test.col.com/>

**项目简介**：面向短剧生产中素材查找低效、分镜整理繁琐、生成准备周期长的问题，构建 AI 驱动的短剧生产平台。前端 React 工作台经 K8s 集群接入，主应用运行 Fastify API 与 Generation Worker；对话 Agent 通过 pi-http-wrapper 包装 Pi CLI 提供自然语言交互入口，生产链部署于火山引擎 AgentKit，由剧本拆解、资产匹配、分镜生成、画面生成与编排调度 5 个 Agent 串联全链路。底层以 RDS PostgreSQL 为事实源，Milvus 支撑语义检索，TOS 存储素材与生成结果。核心安全边界：Agent 层不持有云密钥，付费与资产写入须经 Main 后端审批与额度校验。远期目标为“输入剧本 → 自动拆解 → 分镜 → 生成视频”的端到端自动化，以“AI 做 80% 脏活，人做 20% 关键决策”的模式提升短剧生产效率

**个人职责**：

- **参与 Pi Agent 助手模块的架构设计**：围绕短剧生产流程将（素材检索 / 资产入库 / 生成卡准备 / 任务查询 / 导演台指令）等后端能力封装为 5 个智能体可调工具，并对工具输入输出进行结构化约束；设计 Agent 生命周期管理（会话创建 → 消息流 → SSE 事件归一化 → 审计持久化），支撑用户通过对话完成“找素材 → 选参考 → 准备生成”的生产链路
- **Grill Engine 信息充分性闸门**：设计并实现生成卡提交前的信息充分性检查引擎，采用三层决策树（0-LLM 规则预检 → 1-LLM 语义评估 → 候选/反问降级），在用户调用生成能力前自动判断信息是否充分，不足时反问或提供候选值，避免空泛的生成请求
- **剧本拆解 Agent 编排**：参与剧本拆解模块的两阶段流水线设计——阶段① Agent 循环（7 个工具：编写故事大纲、添加场次、添加角色、添加场景地点、添加道具、添加服装、添加音频）将剧本拆解为场次划分与五类资产候选；阶段② 固定 Skill 单次结构化拆解，生成每个分镜的文本细节、时长与视频提示词；设计草稿/确认分离机制，AI 产出仅入草稿区，人工确认后写入正式表，确保生产数据不受 AI 草稿污染
- **多模态素材入库解析**：负责短剧素材的多模态入库模块，面向视频、音频、图片、Excel 等素材类型，设计统一解析入口；针对 Excel 图文混合资产，设计“模板规则 + 模型识别”解析链路，将非标准表格中的多视图图片、参考图与文本描述自动绑定到对应资产实体；音视频侧通过 ASR、LAS 视频理解、FFmpeg 抽帧与镜头切分，形成“时间戳 + 关键帧 + 文本描述 + 资产标签”的时序索引

- **混合检索链路设计**：面向短剧多模态素材库（角色/场景/道具，短文本 ≤100 字 + 结构化元数据），设计"向量语义召回 + 定制词法召回"双路混合检索架构。针对短文本场景下 **BM25 三因子失效问题**，放弃通用 **BM25 方案**，自研基于 **jieba 分词 + 领域词典注入 + 多字段加权 ILIKE 的词法召回层**，通过 CASE WHEN 多档评分实现可控匹配精度；向量侧采用 HNSW 动态 ef + 标量 expr 前置过滤；双路结果经 RRF (k=60) 融合，并设计规则重排层弥补 RRF 信号压扁问题

#### 技术亮点：

- 构建 300 条短剧素材查询评测集，覆盖角色、场景、道具、分镜参考图等核心场景；混合检索相比单路关键词检索 **Recall@5 从 58.6% 提升至 82.4%，MRR 从 0.41 提升至 0.83**，显著提升 Pi Agent 素材问答和参考图推荐的命中质量
- 剧本拆解模块的提示词版本化机制（PROMPT\_VERSION v2→v11），每次规则变更升号，旧运行按 prompt\_version\_outdated 拒绝续跑，确保线上可审计
- **Pi Agent 工具配额控制（单次 ≤4 次工具调用、prepare\_generation\_card ≤1 次）**，结合 90 秒超时和模型轮次保护（≤2 轮），防止 Agent 跑飞产生非预期费用

### 亚信科技——MiniCoding Agent

### Agent Runtime 框架设计与实现

2025.12 - 2026.04

**技术栈**：Python、ReAct、MCP、Skill、Multi-Agent、JSONL、SWE-bench-Live

**Github**：https://github.com/K80Tom/MiniCode

**项目介绍**：面向移动九天数据分析智能体研发场景的终端 AI 编程助手，基于 ReAct + Agent Runtime 架构构建。围绕"Harness 五要素"（上下文管理 + 工具接口 + 约束 + 验证 + 纠正）设计分层架构，接入 MCP 工具扩展、Skill 能力注入、跨会话记忆、渐进式上下文压缩和五层权限控制，支持研发人员通过自然语言完成数据分析脚本开发、代码检索、文件修改、命令执行、测试反馈和多轮修复，提升数据分析智能体的研发与脚本调试效率

#### 个人职责：

- **上下文与记忆机制**：设计跨会话记忆系统，支持 JSONL 持久化、LLM 自动记忆提取、项目级指令文件加载和历史任务恢复。针对**长程编程会话中 ReAct 循环的累计缓存读取量二次方增长问题**，实现**两层渐进式上下文压缩策略**：第一层对历史对话和工具结果做摘要归档，第二层在检查点处对轨迹做截断重置，将上下文从"只增不改"的线性增长降为分段稳态，支持 8 小时以上连续编程会话保持关键需求、文件变更和测试反馈可追踪不丢失
- **Agent Runtime 架构设计**：独立设计并实现五层分层架构，拆分**模型适配、Agent 推理循环、工具注册与调用、上下文管理、权限控制**等核心模块，支持 OpenAI/Anthropic/OpenAI-Compatible 等多模型接入，并通过 ReAct 模式完成“思考 - 工具调用 - 观察 - 修复”的自动化编程闭环
- **工具系统与权限控制**：实现文件读写、代码编辑、命令执行、Glob/Grep 检索、MCP 工具接入等工具能力。并设计危险命令识别、路径沙箱、读前检查、文件修改状态校验和分级权限确认机制，**平衡 Agent 自动化能力与本地开发安全**
- **评测驱动优化**：基于 **SWE-bench-Live 搭建 Agent 编程任务评测流程**，验证 bug 定位、代码修改和测试修复能力；同时设计上下文信息保留测试，用评测结果反向优化 Prompt、压缩摘要模板和工具调用策略

#### 技术亮点：

- **MCP工具延迟加载**：设计MCP工具延迟加载机制，**百级工具场景下工具描述Token占用减少85%**，避免上下文窗口被工具定义挤占
- **两层上下文压缩**：设计两层渐进式上下文压缩策略，对历史对话、工具结果、文件变更和测试反馈进行摘要归档，支持 8 小时以上连续编程会话保持关键上下文可追踪
- **五层安全隔离**：设计五层权限确认机制，将单次会话权限弹窗从平均30次降至5次以内，避免审批疲劳影响使用体验；可选启用OS级沙箱进一步兜底，内核级隔离支持Agent全自动模式安全执行
- **评测驱动优化**：基于SWE-bench-Live数据集搭建评测流水线，验证Agent的bug定位与修复能力，自主设计上下文信息保留测试，发现并修复压缩摘要模板缺陷，**信息保留率从17%提升至100%**
- **多Agent协作**：设计**多Agent并行协作与Git WorkTree文件级隔离机制**，防止并行文件干扰，突破单Agent上下文窗口瓶颈，跨文件重构任务相比单Agent耗时降低约60%

### 专业技能

- 熟练使用 Claude Code、Codex 等编码 Agent 工具，熟悉 MCP 协议及 Skills 设计原理，具备 Agent 工具链的场景化落地经验
- 熟悉 FastAPI、LangChain、LangGraph、LlamaIndex 等框架，掌握多 Agent 协作设计理念与工具编排
- 熟悉 RAG 全链路优化：多模态文档入库、向量检索与混合检索召回精度提升、Graph RAG 设计
- 熟悉 PostgreSQL 与 Milvus，掌握 SQL 编写、事务与索引原理，熟悉向量数据库的检索投影与降级设计
- 熟悉 Docker 与 Docker Compose，掌握 Git 与 GitHub 团队协作
- 熟悉 Python，了解 Redis 缓存、前端基础（HTML/CSS/JavaScript）及 PyTorch 模型微调基本原理

### 荣誉证书

**证书状况**：英语六级（CET-6），软考初级程序员，CCF计算机软件能力认证（C/C++）

**学术成果**：以第一作者发表两篇CCF-C论文（CSCWD+ICONIP）

#### 竞赛经历：

获得研究生学业奖学金，获得**中国研究生电子设计竞赛省级三等奖**(模型轻量化以及嵌入式平台部署方向)

获得2023 中国计算机应用技术大赛——**全国算法精英大赛本科 B 组银奖**，获得2023“IEERA 杯”国际高校英语阅读挑战赛中国区一等奖

### 科研技术

**[1] Lightweight Medical Image Segmentation Via Cross-Image Global Structural Filtering Distillation.（第一作者）**

**CSCWD 2026（CCF-C），IEEE Xplore 收录（论文号 11582120） DOI: 10.1109/CSCWD68734.2026.11582120**

提出跨图像全局结构过滤蒸馏方法（CIGFD），在像素与区域双粒度去除冗余特征并建模结构关系，将教师模型的全局结构知识高效迁移至轻量学生模型；在 BTCV、Synapse、FLARE 三个公开数据集上一致超越对比方法

**[2] Lightweight Medical Image Segmentation via Cross-Image Region Contrastive and Global Boundary Distillation.（第一作者）**

**ICONIP 2026（CCF-C），已录用**

提出 CIRD+GBD 蒸馏框架：跨图像区域对比蒸馏解决器官类内形态差异大、类间区分度低的问题，全局边界蒸馏消除大器官主导的边界偏差；轻量学生模型 Dice 较基线蒸馏方法最高提升 4.43%