# 汤林夕



**AI 应用开发 / AI Native 全栈 / 智能体开发 / 后端开发**

19922109544 | tangxixi79@gmail.com | 微信：jiujiumaoawu | 24 岁 · 男 · 应届生
抖音博主（技术分享）：jiujiumaoawu · 2000 粉丝，持续增长中 | 个人网站：https://k80tom.github.io/

## 教育背景

**西南科技大学** 软件工程 · 硕士 · 获四川省一等、三等学业奖学金 2024.09 — 2027.06
GPA 3.5/4.0 · 专业前 20% · 研究方向：医学图像分割模型蒸馏、智能体、深度学习

**重庆工程学院** 软件工程 · 本科 2020.09 — 2024.06
GPA 3.4/4.0 · 专业前 20% · Java Web 业务开发：Spring Boot、Spring MVC、MyBatis。

## 实习经历

**小红书 · 创意 Lab1327 研发组** AI Native 全栈开发实习生（转正实习：因团队转正名额调整，现寻求校招机会） 2026.07 — 至今
参与 Dear Aura 记忆与异步调度、反馈信箱 / 公告全栈研发；负责搜广推内容增长平台 CreativeFlow 的录屏快剪 Agent 研发。

**中文在线 · 技术创新部门** AI 提效实习生 2026.01 — 2026.06
参与 AI 短剧生产平台建设，负责素材解析入库与 RAG 混合检索，参与 Agent 工具及生成流程编排。

**亚信科技 · 技术部门** AI Agent 开发实习生 2025.09 — 2026.01
参与移动九天数据分析场景下的 AI 编程工具研发，承担模型接入、工具扩展、上下文管理及功能验证。

## 项目经历

### Dear Aura | AI Native 个性化陪伴应用 · 全栈与 Agent 研发

小红书 · 创意 Lab1327 研发组 · 2026.07 — 至今

Go · Thrift RPC · GORM · MySQL · Redis · RedIM · SwiftUI / MVVM · Android · Vue 3 / TypeScript · Apollo
**产品地址：** https://www.dearaura.com/apps/aura-web
**项目简介：** Dear Aura 是一款已上线 iOS / Android 的 AI 生活陪伴与自我探索 App，结合用户画像与历史互动，提供个性化聊天、好运日报、心愿日记等功能。采用原生移动客户端、Vue 运营管理端与 Go 服务端，通过 **Thrift IDL / SDK、Edith HTTP 映射与内部 RPC**连接业务模块，以 MySQL、Redis、RedIM 支撑数据持久化、缓存、异步任务及实时消息。负责 **AI Native 全栈开发**，覆盖服务端、管理端及 iOS / Android 客户端，并参与对话记忆、上下文组织和日报异步链路研发。

**个人职责：**

- **反馈信箱与公告全栈研发：**负责 **Go 后端、Thrift IDL / SDK、Edith 接口映射、Vue 管理端及 iOS / Android 客户端**研发，完成图文反馈、消息分页、官方回复、已读未读、运营公告、Push 及 Deep Link 跳转，打通“用户反馈—后台处理—官方回复—客户端提醒”闭环；结合 **Proxyman 抓包与服务日志**排查接口契约、环境配置和跨端状态问题。
- **事务并发与上下文缓存：**通过 **MySQL 事务、行锁及复合唯一键**保障消息序号分配与重复提交幂等，以快照分页、已读水位维护列表和未读红点，通知失败不回滚已提交消息；基于 RedIM 原始消息与 Redis 会话投影，按 Token 预算组织近期原文、Episode / Rollup 摘要，通过 **Lua CAS 防止旧摘要覆盖新消息，租约锁与写入屏障抑制重复回源和旧记忆回填。**
- **日报异步任务调度：**参与 **即时请求 / 后台预生成双队列与独立 Worker 池**研发，隔离两类任务；通过 Lua 原子抢占、租约续期与令牌校验支持超时接管，拒绝失去任务归属的旧 Worker 续期或提交，结合 **Checkpoint 与有限重试**复用已完成阶段，减少中断后的重复生成。
- **时间记忆与事件按需调用：**研发 **A 时间标注与原话溯源＋B 结构化事件账本**，保留事件主体、发生时间、计划 / 取消状态及更正关系，并将事件抽取移至回复后异步执行。针对旧事件反复注入导致的话题回流，研发只读历史回查工具，由**主模型结合现有 Sidecar 判断本轮是否需要调用**，按预算加载当前会话的时间原文与事件卡；结果仅供本轮续答，不写回持久工作状态，并取消压缩入口对事件账本的直接注入。
- **对话语气与事实归因优化：**针对刻薄回复、动机臆测和重复说教，联合调整人格提示、系统语气边界与本轮回答约束；区分 **用户原话、工具事实与助手历史推断**，落实用户最新纠正优先、拒绝后停止推进，避免旧回复中的猜测经摘要固化为用户事实；复用现有主模型与 Sidecar，不新增独立语气分类或生成后改写调用。
- **长期记忆治理方案设计：**针对固定注入最近记忆、同义 Key 重复及旧事实误覆盖，设计 **核心画像受控字段＋长期事实混合检索＋时间事件独立读取**的分层方案，规范主体与标准 Key，管理新增、确认、替换、合并与撤回。按类别设置**差异化时间衰减**：稳定资料不自动衰减，阶段性目标与状态到期校验，偏好与习惯降低召回权重，历史经历保留并支持明确回查；规划 **BM25 / 向量召回、RRF 融合与有效状态复核**，按相关性和 Token 预算注入，并设计事务 Outbox 与版本校验机制保障索引一致性。

**技术亮点：**

- **时间记忆效果与性能取舍：**基于 **44 类场景、1,056 次模型回答**开展未优化、A、同步 A＋B、异步 A＋B 对照，事件完整正确率由 **66.7% 提升至 91.7%**，时间严格合格率由 **36.5% 提升至 99.5%**；四组离线回复均时分别为 **0.86 / 0.95 / 1.81 / 0.96 秒**，异步较同步降低约 **47%**，时间合格率持平，事件指标低 **2.1 个百分点**，异步抽取耗时另计。既有时间记忆方案完成个人泳道自测，并协同专职 QA 使用测试样例开展硬压缩回归。
- **语气质量量化回归：**基于 **24 个历史场景、72 条 BETA 模型回放**开展候选版本对照；已完成双评审的 v8 候选中，明确及严重语气问题由 **19/72 降至 2/72（26.4%→2.8%）**，下降 **23.6 个百分点**，采用两位评审问题集合的合并口径。
- **缓存抗击穿与并发复用：**针对会话缓存失效后的集中访问，以 **会话级租约锁与持有者校验**合并回源重建，让并发请求复用同一份缓存结果；在 **20 并发、20 轮本地模拟冷缓存测试**中，**400 次加载全部返回完整消息，每轮仅触发 1 次重建，累计 20 次**，验证缓存失效场景下的并发控制与数据完整性。

### CreativeFlow | 搜广推 AI 内容创作与投放增长平台

小红书 · 创意 Lab1327 研发组 · 2026.07 — 至今

Go / Gin · React / TypeScript · MySQL · 对象存储 · SSE · 多模型适配 · FFmpeg · Android 自动化
**业务示例：**圆周旅迹 · https://www.pitravel.cn/（真机操作录屏与自动剪辑）
**项目简介：**CreativeFlow 是面向搜广推业务的 **AI 内容创作与投放增长平台**，覆盖运营分析、图文与视频创作、素材管理、自动化投流及数据复盘。我负责**视频创意工具下的录屏快剪 Agent 设计与全栈研发**：将运营提供的录屏 / 剪辑 Skill 与产品资料编译为可执行 Recipe，驱动视觉 Agent 在云真机完成 App 演示，经自动剪辑、模型质检与人工复核产出推广视频。近期借鉴 **Harness² 受控自进化思路**，设计并推进多产品接入、执行版本冻结及基于任务证据的策略与经验迭代。

**个人职责：**

- **Harness² 执行架构设计：**针对产品页面规则与 Worker 耦合的问题，设计“**通用 Core＋产品 Pack＋设备执行层**”，分别负责阶段调度与恢复、产品流程与完成条件、真机操作与录屏。规划冻结 Pack、工具、子 Agent 及校验规则版本，启动前检查环境；模型提出动作或建议，由宿主统一校验和执行，保持设备单一写入者。
- **产品接入与模板全栈研发：**完成 Go 接口与 React 产品 Pack 管理页面的本地实现，串联 **Skill 上传→结构化编译→独立复核→契约验证→版本发布→场景模板复用**。模板修复仅修改审核指出的字段；通过来源摘要、任务快照、行锁及事务保障版本一致性和并发发布幂等，运行中任务及重试沿用冻结版本。
- **视觉操作 Agent 与工作记忆：**构建“**截图观察→阶段上下文→模型决策→程序校验→真机执行→回执复核**”循环。保存当前阶段、待确认动作、失败位置、完成证据和剩余预算，为动作及回执记录时间与状态，避免旧画面、旧坐标及未确认动作影响后续决策。
- **上下文组织与缓存复用：**按“**固定协议与 Skill→稳定参数与 Recipe→当前阶段→动态事件、异常及截图**”组织提示词，仅折叠程序确认成功的历史动作，保留近期动作、失败证据与关键回执；稳定前缀支持提示词缓存，完整执行记录独立留存。
- **受控自进化与长期经验：**设计“**执行证据→问题归因→候选修改→回放 / 真机 Probe→效果比较→采用或保留原版**”闭环，围绕 Prompt、Skill、工具契约及记忆策略提出改进，以成功率、错误动作、耗时和成片质量验证。经验按产品、阶段及设备能力筛选，在 Token 预算内注入，由模型结合实时画面决定采用；有效经验逐步确认，有害经验停用并保留反例。**已实现证据与候选状态管理，真机 Probe 及完整自进化流程正在接入。**

- **剪辑 Agent 与中断恢复：**将剪辑 Skill 转换为时序与质量约束，结合原片时间戳和动作边界帧生成 EDL，经后端校验后由 FFmpeg 渲染。以 **原片 Checkpoint** 保存录制结果与完成证据，剪辑失败后复用原片续跑；经模型独立复核与人工验收定位问题，按证据限次重采样、重规划或重渲染。

**技术亮点：**

- **跨模型执行稳定性：**通过**结构化 Recipe、分阶段决策、程序校验与回执确认**，结合独立复核与受控修复，降低流程对单一模型的依赖。在 Opus、GPT、Kimi、豆包各 **10 次固定样例测试**中，模板创建、录屏及剪辑三个阶段的通过率均由 **16/40（40%）提升至40/40（100%）**；其中豆包各阶段由 **0/10 提升至10/10**，成片通过模型审核与人工质检。
- **上下文精简与推理开销控制：**通过**稳定前缀重排、已确认动作折叠及动态状态追加**，26 轮历史任务回放中，计划与历史载荷由 **39,806B 降至 24,679B（减少约38%）**；Skill 不变的历史自测中，**Prompt Cache 命中率由约30%提升至90%以上**。等待阶段引入本地图像差分，**48 次检查中43 次由本地完成，仅5次调用模型**，减少无变化画面下的重复判断。

汤林夕 · AI 应用与全栈开发　　19922109544 · tangxixi79@gmail.com

### AI 短剧智能体生产平台 | Agent 工具与多模态素材检索

中文在线 · 技术创新部门 · 2026.01 — 2026.06

TypeScript · Python · React · Fastify · PostgreSQL · Milvus · TOS · Pi Agent · Docker / Kubernetes

**在线产品：**https://shortdrama.col.com/ · 分镜制作演示（需登录）↗

**项目简介：**面向导演在短剧制作中素材查找低效、剧本拆解繁琐、生成准备不充分的问题，参与 AI 短剧智能体生产平台研发。平台采用 **React 工作台＋Fastify 业务后端**，以 PostgreSQL 管理项目、资产和任务，Milvus 支撑语义检索，TOS 存储媒体；通过 **Agent 工具与 CLI 接口**开放素材检索、项目资产关联、剧本拆解和生成任务等能力，支持导演通过工作台或自然语言完成制作准备。我主要负责**多模态素材解析入库与 RAG 混合检索**，并参与 Agent 工具、信息充分性检查及剧本拆解流程研发。

**个人职责：**

- **多模态素材解析入库：**负责图片、视频、音频及 Excel 素材的解析入库；针对非标准 Excel 图文混合资产，结合**模板规则＋模型识别**，将多视图图片、参考图与文本描述绑定到对应资产实体。以 PostgreSQL 保存结构化资产与来源信息，TOS 保存媒体文件，并异步同步向量索引，支撑素材复用与检索。
- **RAG 检索增强与混合召回：**为**导演检索工作台与 Agent 素材问答**提供共用检索能力。针对短文本和角色、场景、道具等领域实体，设计“**向量语义召回＋定制词法召回**”，结合 jieba 分词、领域词典、多字段加权匹配及元数据过滤，迭代融合排序与规则重排，提高素材查找和参考图推荐的匹配质量。
- **Agent 工具与会话链路：**参与 Pi Agent 助手研发，将素材检索、项目资产关联、生成卡准备、任务查询和导演台指令封装为 **5 个受控业务工具**，约束输入输出与操作权限；结合会话管理、SSE 事件及审计记录，支持通过对话完成“**找素材→选参考→准备生成**”。
- **Grill 信息充分性检查：**设计并实现生成准备前的检查流程，采用“**规则预检→模型语义评估→候选补全 / 反问**”，判断素材、参数和创作要求是否充分；将可确定的检查交给程序，必要时再调用模型，引导用户补齐缺失信息。
- **两阶段剧本拆解：**参与“**Agent 多工具拆解→固定 Skill 结构化拆镜**”流水线，先通过 7 类业务工具提取梗概、场次及角色、场景、道具、服装、音频候选，再生成分镜细节、时长和视频提示词。通过原文引用、结构校验及草稿确认流程控制正式写入，并记录剧本与提示词版本，支持结果追溯。

**技术亮点：**

- **素材检索效果提升：**在此前 **300 条素材查询评测**中，对比单路关键词检索，混合检索的 **Recall@5 由58.6%提升至82.4%，MRR 由0.41提升至0.83**，覆盖角色、场景、道具及分镜参考图等查询场景。
- **Agent 执行与费用约束：**将工具调用限制落实在运行时，单次请求**最多4次工具调用、最多准备1张生成卡，设置90秒超时**；生成卡准备与付费任务提交分离，实际生成仍经业务后端确认与额度校验。
- **拆解结果可追溯：**绑定剧本版本、提示词版本与候选来源，规则变化后拒绝旧版本运行继续执行；通过草稿与正式数据分离、确认事务及幂等处理，避免重复确认和过期结果写入。

### MiniCoding Agent | 终端 AI 编程助手

亚信科技 · 技术部门 · 2025.09 — 2026.01

Python · ReAct · MCP · Skill · Multi-Agent · JSONL · SWE-bench-Live

**GitHub：**https://github.com/K80Tom/MiniCode

**项目简介：**MiniCoding Agent 是服务于**移动九天数据分析研发的终端 AI 编程助手**，通过自然语言生成、执行和修复数据分析脚本，将代码检索、文件编辑与命令执行组织为 ReAct 循环，结合跨会话记忆、MCP / Skill 和分级权限控制支持长程任务。

**个人职责：**

- **上下文与记忆机制：**参与 JSONL 会话持久化、LLM 记忆提取、项目指令加载与历史任务恢复；针对长程 ReAct 会话的上下文累积，实现“**摘要归档＋检查点截断**”两层压缩，保留关键需求、文件变更与测试反馈。
- **Agent Runtime 与模型接入：**参与模型适配、推理循环、工具注册调用、上下文管理和权限控制的分层研发，接入 OpenAI / Anthropic / OpenAI-Compatible 接口，通过 ReAct 完成工具调用、观察与修复循环。
- **工具系统与权限控制：**实现文件读写、代码编辑、命令执行、Glob / Grep 与 MCP 工具接入；完善危险命令识别、路径访问限制、读前检查、文件修改状态校验及分级确认机制。
- **评测与并行协作：**基于 SWE-bench-Live 验证问题定位、代码修改和测试修复，结合信息保留测试调整摘要模板；参与多 Agent 并行执行，以 **Git Worktree** 隔离目录并验证跨文件修改流程。

**技术亮点：**

- **MCP 工具延迟加载：**百级工具场景下，工具描述 Token 占用**减少 85%**，为任务上下文保留更多空间。
- **上下文与权限优化：**两层压缩支持 **8 小时以上**长会话追踪；单会话权限弹窗由平均 **30 次降至 5 次以内**。
- **多 Agent 协作：**结合并行执行与工作目录隔离，跨文件重构测试中，耗时较单 Agent **降低约 60%**。

## 专业技能

**AI 工程：**Claude Code / Codex、MCP / Skills、ReAct、多 Agent 编排、RAG / 混合检索、LangChain / LangGraph。

**后端与交付：**Go / Python、MySQL / PostgreSQL、事务 / 索引 / 幂等、Redis、Milvus、Thrift 联调、Docker / Compose、Git；了解 React / SwiftUI 与 PyTorch 微调。

## 科研成果

**CIGFD | 医学图像分割蒸馏 · 第一作者 · CSCWD 2026（CCF-C）**

IEEE Xplore 收录 · DOI：10.1109/CSCWD68734.2026.11582120

提出跨图像全局结构过滤蒸馏，结合注意力特征压缩、显著特征过滤与跨图像对比学习，在 BTCV / Synapse / FLARE 验证；Synapse Dice **90.17%→93.53%（+3.36 个百分点）**，ENet 保持 **0.35M 参数、2.01G FLOPs**。

**CIRGBD | 区域对比与全局边界蒸馏 · 第一作者 · ICONIP 2026（CCF-C，已录用）**

以 CIRD 建模跨图像器官区域关系，以 GBD / Sobel / KL 对齐边界，在 **3 个数据集、6 组师生组合**验证；FLARE Dice **83.27%→87.44%（+4.17 个百分点）**，mIoU **80.19%→84.62%（+4.43 个百分点）**，学生模型复杂度不变。

## 荣誉与证书

**奖项：**研究生学业奖学金；中国研究生电子设计竞赛省级三等奖；2023 全国算法精英大赛本科 B 组银奖；2023 IEERA 杯国际高校英语阅读挑战赛中国区一等奖。

**证书：**CET-6 · 软考初级程序员 · CCF 计算机软件能力认证（C/C++）